



EL DATO QUE ORIGINÓ ESTE ESTUDIO

~197.000 personas

con COVID-19 confirmado a las que el sistema **nunca les hizo seguimiento.**

En epidemiología, ninguna es un caso aislado:

cada una es una cadena de contagio que pudo no detenerse.

¿Dónde están esas brechas, a quiénes afectan y por qué persisten?



UNIVERSIDAD
NACIONAL
DE COLOMBIA

COBERTURA DE SEGUIMIENTO EPIDEMIOLÓGICO EN COLOMBIA: ANÁLISIS DE LOS DATOS PRASS 2020–2022

EXPLORACIÓN, PREPROCESAMIENTO, EDA Y MODELADO GLM BINOMIAL

Jabes Esteban Monroy Becerra

Universidad Nacional de Colombia — Sede Manizales

Especialización en Estadística | Junio 2026

EL ESTADO RASTREÓ CADA CASO. ¿A QUIÉNES SE LES ESCAPÓ?

El problema:

Entre 2020 y 2022 Colombia reportó más de **3,5 millones de casos** de COVID-19 bajo el programa PRASS. Cada caso debía ser rastreado y aislado.

Una brecha en ese rastreo no es un error administrativo:

es una cadena de contagio no interrumpida.

¿Qué hace este trabajo?

Cuantifica esa brecha con precisión estadística, identifica a quiénes afecta y construye un modelo predictivo que explica *por qué* ocurre.

Indicador	Valor
Registros analizados	339.646
Casos totales	3.532.353
Cobertura ponderada	94,4 %
Sin seguimiento	~197.000
Período	2020–2022
Fuentes	3
Departamentos	33
Municipios	1.121
Entidades	68

Fuente: datos.gov.co, conjunto r6r5-w84k

¿QUÉ ES PRASS Y POR QUÉ ES CRÍTICO MODELARLO?

RELEVANCIA EPIDEMIOLÓGICA Y ANALÍTICA

Programa PRASS (Pruebas, Rastreo y Aislamiento Selectivo Sostenible):

- Mecanismo central de contención durante la pandemia.
- Por cada caso debía contactar, rastrear y monitorear.
- Indicador binario: ¿recibió seguimiento? (1 = sí, 0 = no).

¿Por qué modelar la cobertura?

- La cifra global (94,4 %) *oculta* brechas por fuente, territorio y entidad.
- Identificar brechas permite **priorizar intervenciones de salud pública**.
- La pregunta no es descriptiva: es **causal y predictiva**.

El 5,6 % no seguido en perspectiva:

Fuente	Sin seg.
CONFIRMADOS	~4 %
SOSPECHOSOS	~20 %
NO AFILIADOS	~25 %

En población no afiliada, **1 de cada 4 casos** no recibe seguimiento. Sobre 38.311 casos: ~9.400 personas sin rastreo activo.

Cada caso no rastreado es un potencial clúster.

DESCRIPCIÓN DE LA BASE DE DATOS

ESTRUCTURA, VOLUMEN Y CARDINALIDAD

Ficha técnica:

Atributo	Valor
Registros	339.646
Variables originales	12
Observación	Agregado por grupo
Período	04/05/2020 – 18/05/2022
Fecha mediana	21/05/2021
Nulos	0
Duplicados	0

Nota: cada fila es un *agregado* (no un paciente): suma de casos por fuente, fecha, municipio y entidad.

Cardinalidad de categóricas:

Variable	Categorías
Fuente	3
Departamento	33
Semana epidemiológica	53
EntidadRegistro	68
FechaRegistro	428
Municipio	1.121

Fuente dominante:

CONFIRMADOS: 300.309 (88,4 %).

SOSPECHOSOS: 32.608 (9,6 %).

No afiliada: 6.729 (2,0 %).

PARTE I: DIAGNÓSTICO DEL DATO CRUDO

ESTADÍSTICOS DESCRIPTIVOS Y OUTLIERS

Estadísticos de conteo:


	Media	Med.	Máx.
NumeroCasos	10,4	2	31.654
ConSeguim.	9,8	1	31.654
SinSeguim.	0,6	0	2.519

Media $\gg$ mediana: **asimetría positiva severa**. Cola derecha hasta 31.654.

Outliers por IQR ($Q1=1$, $Q3=4$):

- NumeroCasos: **13,70 %**
- SinSeguimiento: **12,97 %**
- ConSeguimiento: **12,89 %**

No son errores: son el patrón natural del conteo epidemiológico.



Boxplots de variables de conteo. Cola larga; los outliers reflejan brotes reales.

PARTE I: HALLAZGOS CRÍTICOS DE CALIDAD

LO QUE EL DATO REVELÓ ANTES DE SER PROCESADO

Técnica	Hallazgo
Nulos	0 en las 12 variables
Duplicados	0 (0,00 %)
Col. constante	FechaCorte fija → eliminada
Espacios dobles	EntidadRegistro: 58.396 filas → corregidas
Coherencia	Total = Con + Sin en 100 %
Porcentajes	CORRUPTOS : $100 \% = 10^{22}$

Test de Little (MCAR): no aplica — sin datos faltantes.

Hallazgo crítico — dato crudo:

PctSin	PctCon
0	1e22
0	1e22
3.85e20	9.6e21

Decisión: recalcular desde conteos:

$$Cob = \frac{Con}{Total} \times 100 \in [0, 100]$$

El recálculo produce una variable coherente:
media = 91,95 %, desv. = 25,15 %, mediana = **100 %**.

PARTE II: PIPELINE DE PREPROCESAMIENTO

TRANSFORMACIONES ENCAPSULADAS EN `UTILS.PREPROCESAR()`

Transformación Resultado	
to_datetime	Rango confirmado: may-2020 a may-2022
Split territorial	Crea DeptoNombre/Code y MuniNombre/Code
Estandarizar texto	0 espacios dobles (vs. 58.396)
Recalcular cobertura	Rango [0, 100] % restaurado
Eliminar columnas	FechaCorte + 2 corruptas + territoriales originales
Tipado semántico	category, ordinal (semana), str (DIVIPOLA)

Dataset df_prep:



Variables	13
Tipos correctos	13/13
Nulos	0

¿Por qué DIVIPOLA como str? Los códigos (05, 25, 76...) son identificadores, no números; como entero inducirían orden espurio.

¿Por qué no imputar nulos? No hay nada que imputar: el agregado por grupo nunca produce vacíos.

EDA I: DISTRIBUCIÓN DE LA VARIABLE OBJETIVO

UNA VARIABLE QUE NO ES “NORMAL” EN NINGÚN SENTIDO




KDE de cobertura (izq.) y log(casos) (der.).

Histograma de cobertura. La masa se concentra en 100 %.

Lectura: 87 % de grupos tienen cobertura del 100 %. La cola inferior (< 50 %) concentra la brecha: pequeña en registros, grande en consecuencias. Media = 91,95 %, desv. = 25,15 %; mediana = Q1 = Q3 = 100 %. La distribución **invalida modelos Gaussianos**: acotada en $[0, 100]$ y bimodal.

EDA I: COMPOSICIÓN CATEGÓRICA

¿QUIÉN REPORTA, DÓNDE Y CON QUIÉN?



Distribución por Fuente (pastel), Top-10 departamentos y Top-10 entidades por registros.

Lectura: CONFIRMADOS domina (88,4 %). Antioquia (40.027) y Cundinamarca (38.753) concentran el 23 % de los registros. NUEVA EPS S.A. lidera con 54.641 (16 % del total). La concentración en pocos actores amplifica el impacto de sus brechas.

EDA II: COBERTURA PONDERADA VS. PROMEDIO SIMPLE

94,4 % vs. 91,95 %: EL ESTIMADOR QUE IMPORTA

Cobertura ponderada por casos:


$$\bar{p}_w = \frac{\sum \text{Con}_i}{\sum \text{Total}_i} = \mathbf{94,39\%}$$

Promedio simple de filas:

$$\bar{p} = \frac{1}{n} \sum \frac{\text{Con}_i}{\text{Total}_i} = \mathbf{91,95\%}$$

El promedio simple pondera igual 1 caso y 10.000; los grupos pequeños tienen más brechas extremas. $\bar{p}_w$ refleja la experiencia del **caso individual**.

El promedio simple subestimaría la cobertura en 2,4 pp.




Cobertura ponderada por fuente.

Fuente	Cobertura
CONFIRMADOS	95,99 %
SOSPECHOSOS SIVIGILA	79,93 %
POBL. NO AFILIADA	75,45 %

EDA II: HETEROGENEIDAD TERRITORIAL

NO TODOS LOS DEPARTAMENTOS SON IGUALES ANTE EL SEGUIMIENTO



10 departamentos con menor y mayor cobertura ponderada.

Extremos territoriales:

Mayor cobertura

La Guajira ≈98 %

Caquetá ≈98 %

Caldas ≈98 %

Menor cobertura

Chocó ≈73 %



San Andrés ≈84 %

Valle del Cauca ≈84 %

La brecha en Chocó (73 %) equivale a **27 % de casos sin rastreo**: un reservorio de transmisión no controlada.

EDA III: CORRELACIÓN Y DISPERSIÓN BIVARIADA

LA COBERTURA NO TIENE RELACIÓN LINEAL CON VARIABLES NUMÉRICAS




Tamaño vs. cobertura (izq.) y casos vs. seguidos (der.),
escala log.

Matriz de Pearson. Cobertura: $|r| \leq 0,12$.

Lectura: la Pearson débil ($\leq 0,12$) no indica ausencia de relación, sino **saturación en 100 %**. El scatter (izq.) muestra la relación no lineal: los grupos pequeños tienen alta varianza y los grandes convergen a cobertura alta. Esto valida el GLM binomial ponderado por N_i .

EDA IV: CRUCE DEPARTAMENTO × FUENTE

LAS BRECHAS VIVEN EN LA INTERACCIÓN, NO EN UN FACTOR AISLADO



Patrón consistente:

- En cada departamento, CONFIRMADOS siempre supera a los demás.
- Amazonas: 92 % en CONFIRMADOS, pero solo 7 % en NO AFILIADOS.
- Atlántico: 97 % CONFIRMADOS, 60 % en NO AFILIADOS.
- Chocó: el peor en todas las fuentes (76 %, 82 %, 51 %).

Implicación: la brecha **no es solo territorial** ni **solo de fuente**: vive en la *interacción*. Anticipa el término Fuente × Departamento.

Cobertura (%) por departamento y fuente. Verde = alta; rojo = brecha.

EDA V: EVOLUCIÓN TEMPORAL 2020–2022

EL SISTEMA AGUANTÓ LAS OLAS — LA CAÍDA FINAL ES PROGRAMÁTICA



Arriba: casos por mes (olas epidémicas). Abajo: cobertura mensual (%).

Lectura: cuatro olas visibles (pico ≈ 600.000 casos en jun-2021). La cobertura se mantiene estable en 95–99 % durante los picos: **el sistema no colapsó operativamente**. La caída al 35 % en may-2022 refleja el **cierre programático** del PRASS, no una falla del rastreo.

¿LA DISPERSIÓN DE COBERTURA ES RUIDO O ESTRUCTURA?

K-MEANS + ÁRBOL DE DECISIÓN COMO VALIDACIÓN

Estrategia: K-Means ($k = 4$) sobre perfil estandarizado [cobertura, $\log(\text{Casos})$, fuente]. La silueta crece hasta $k = 4$ ($\approx 0,72$) y se estabiliza.

Cluster	Perfil	% casos	Cob. pond.
C1	Régimen dominante (CONFIRMADOS)	88,6 %	97,5 %
C2	Brecha dura (CONFIRMADOS)	2,7 %	12,4 %
C3	SOSPECHOSOS SIVIGILA	7,6 %	90,2 %
C4	POBLACIÓN NO AFILIADA	1,1 %	75,5 %

Validación (árbol de decisión):

- Exactitud de predicción del cluster: $\approx 0,999$
- Importancia: **fuelle (0,56)** > cobertura (0,44) $\gg$ tamaño (0,000)
- Eta-cuadrado de cobertura entre clusters: $\eta^2 = 0,886$

La dispersión es estructural, no ruido. Cuatro regímenes nítidos coexisten: esto no solo justifica modelar, lo exige.

PESO DE PREDICTORES ANTES DEL MODELO

REDUCCIÓN DE DEVIANZA DE GLM DE UN SOLO FACTOR

Objetivo: anticipar qué predictores aportan más. Métrica: % de devianza nula reducida por cada predictor solo.

Predictor	% Devianza	gl	Lectura
Fuente	12,1 %	2	Más eficiente: máximo por gl
EntidadRegistro	35,7 %	67	Alta capacidad, alto costo paramétrico
Departamento	5,0 %	32	Aporte moderado relativo a sus gl
Semana	0,3 %	1	Irrelevante para predecir cobertura

Implicación: Fuente explica el 12,1 % con *solo 2 grados de libertad*. La entidad explica más (35,7 %) pero a costo de 67 parámetros — riesgo de sobreajuste. La semana es descartable: el tiempo no predice la cobertura una vez controlados fuente y territorio.

MARCO TEÓRICO: ¿POR QUÉ GLM BINOMIAL?

EL PROCESO GENERADOR DE DATOS DICTA LA FAMILIA

Formulación: de N_i casos en el grupo i , k_i reciben seguimiento:

$$k_i \sim \text{Binomial}(N_i, p_i), \quad \text{logit}(p_i) = \mathbf{x}_i^\top \boldsymbol{\beta}$$

Ponderado por N_i ; estimación por máxima verosimilitud.

Familia	Soporte	¿Por qué no?
Normal	$\mathbb{R}$ cont.	Cobertura acotada; varianza heterocedástica
Gamma	$\mathbb{R}^+$ cont.	Para magnitudes sin cota superior
Poisson	$\{0, 1, 2, \dots\}$	k_i acotado por N_i ; no modela la proporción
Binomial	$\{0, \dots, N_i\}$	Proceso exacto: k éxitos en N ensayos

¿Por qué no regresión beta? La beta no pondera por N_i . El GLM binomial incorpora el tamaño del grupo en la verosimilitud, dando más peso a los grupos informativos.

PREPARACIÓN DE LA MATRIZ DE MODELADO

103 PARÁMETROS — PARTICIÓN 80/20

Partición:

Conjunto	Filas
Entrenamiento (80 %)	271.716
Prueba (20 %)	67.930
Total	339.646

Matriz de diseño X :

Bloque	Col.
Intercepto	1
Fuente (dummies)	2
Departamento	32
EntidadRegistro	67
Semana (continua)	1
Total	103

Decisiones de diseño:

- **Referencia Fuente:** CONFIRMADOS.
- **Municipio excluido:** 1.121 dummies crearían separación perfecta en municipios pequeños — inestabilidad numérica.
- **Semana continua:** 1 gl para tendencia temporal sin sobreajustar.
- **Ponderación:** cada fila pesa N_i en la verosimilitud.

La partición garantiza representación de todas las fuentes en ambos conjuntos. El conjunto de prueba no se toca hasta la evaluación final.

RESULTADOS DEL MODELO BASE

AJUSTE, ODDS RATIOS E INTERPRETACIÓN CAUSAL

Bondad de ajuste:

Métrica	Valor
Parámetros	103
Pseudo- R^2 deviz.	0,514
Dispersión ϕ	2,768
Brier (modelo)	0,0425
Brier (baseline)	0,0548
Reducción Brier	22,4 %
AUC-ROC	0,8776

Calibración por fuente:

Fuente	Obs. %	Pred. %
CONFIRMADOS	96,04	96,02
SOSPECHOSOS	78,85	78,43
NO AFILIADOS	78,99	74,23

Odds ratios por fuente (ref.: CONFIRMADOS):


Fuente	OR	IC 95 %
SOSPECHOSOS	0,088	[0,086; 0,089]
NO AFILIADOS	21,33	[17,3; 26,3]
Semana	0,987	[0,986; 0,987]

OR sospechosos = 0,088: once veces menos chances de seguimiento que confirmados, controlando territorio y entidad ($p < 0,001$).

Paradoja de Simpson (NO AFILIADOS): el OR marginal sugiere brecha, pero el OR ajustado > 1 . La inequidad es *territorial*, no de afiliación.

ODDS RATIOS TERRITORIALES AJUSTADOS

HETEROGENEIDAD ENTRE DEPARTAMENTOS AL CONTROLAR FUENTE Y ENTIDAD



8 departamentos con menor OR (brecha, izq.) y 8 con mayor OR (der.).


Lectura:

El OR ajustado de Chocó ($\approx 1,5$) y Vaupés ($\approx 1,7$) muestra que, al controlar por fuente y entidad, la brecha territorial es **menor de lo que aparenta marginalmente**.

La inequidad observada en el mapa crudo se explica en gran parte por la *composición de fuentes* de cada departamento, no por el territorio en sí.

CALIBRACIÓN DEL MODELO POR DEPARTAMENTO

PREDICHO VS. OBSERVADO, PONDERADO POR CASOS



Burbuja $\propto$ casos. Diagonal = calibración perfecta.


Lectura:

La calibración es **buen**a en los **departamentos grandes** (burbujas grandes, cercanas a la diagonal): donde hay más casos, el modelo predice con precisión.

La dispersión aumenta en departamentos pequeños, coherente con la **sobredispersión** que se diagnostica más adelante.

CLASIFICACIÓN Y CURVA ROC

EL UMBRAL ES UNA PALANCA DE DECISIÓN DE SALUD PÚBLICA



ROC (AUC= 0,878) y matriz de confusión en umbral Youden (0,95).

Métricas por umbral:

	0,50	0,90	0,95
Accuracy	0,948	0,872	0,721
Sensib.	0,994	0,886	0,713
Especif.	0,212	0,635	0,863
AUC		0,878	

¿Por qué accuracy (94,8 %) engaña?

El 94 % de casos son seguidos: un clasificador trivial alcanzaría esa exactitud.

Umbral Youden (0,95): la especificidad sube al 86,3 % — detecta 33.882 de 39.245 casos sin seguimiento.

Diagnóstico del modelo base:

- **Sobredispersión:** $\phi \approx 2,77$ (la binomial asume $\phi = 1$). La varianza entre grupos excede lo esperado.
- **Causa:** heterogeneidad intrínseca entre grupos, irreducible por covariables observadas (el clustering lo demostró).
- **Consecuencia:** errores estándar subestimados por $\sqrt{2,77} \approx 1,66$. IC demasiado estrechos.

Estrategia: añadir Fuente $\times$ Departamento y ajustar como **quasi-binomial** (ϕ fijada en la dispersión de Pearson).

Comparación de modelos:

Modelo	R_D^2	ϕ	Brier
Base	0,514	2,77	0,0425
+ interacción	0,529	2,94	0,0421

La interacción mejora moderadamente el ajuste, pero la sobredispersión **persiste** ($\phi \approx 2,9$). El quasi-binomial corrige la inferencia ($ES \times \sqrt{\phi} \approx 1,71$) sin cambiar las estimaciones puntuales.

Solución de fondo: modelo jerárquico (beta-binomial / GLMM) con efectos aleatorios.

La idea, en simple:

- Antes, cada departamento tenía su propia “perilla” fija; donde hay pocos casos, esa perilla se vuelve inestable.
- El GLMM los trata como miembros de una **misma familia**: cada uno puede diferir, pero los de pocos datos se **acercan con suavidad al promedio nacional** (*shrinkage*).

Cómo se ajustó: Fuente como efecto fijo y el **territorio como efecto aleatorio**, sobre una muestra estratificada por Departamento $\times$ Fuente.

Hallazgo clave:

La diferencia real entre departamentos:

$$SD \approx 0,50$$

(en escala logit)

Es **heterogeneidad territorial medida**, no ruido. El GLMM **no borra** la dispersión del clustering: la **explica** como variación entre grupos.

¿EL GLMM PREDICE MEJOR? NO — Y ESTÁ BIEN

SECCIÓN 49 — CAPACIDAD PREDICTIVA: GLMM FRENTE A GLM

Error de predicción (Brier, prueba):

Modelo	Brier
GLM binomial	0,043
GLMM	0,051

Menor es mejor: el GLM acierta más.

¿Por qué el GLMM no gana?

- Usa **menos información**: solo Fuente + territorio (sin entidad ni semana).
- El *shrinkage* sacrifica ajuste fino a cambio de **estabilidad**.

En palabras simples:

el **GLM acierta más**; el **GLMM es más honesto** sobre lo que no sabe: da márgenes de error realistas que el GLM subestimaba por la sobredispersión.

¿ES BUENO EL GLM? COMPARADO CON LO SIMPLE, SÍ

SECCIÓN 50 — BRIER EN PRUEBA FRENTE A MODELOS DE REFERENCIA

Modelo	Brier
Referencia (cobertura global)	0,055
Solo Fuente	0,052
GLM completo	0,043

−22% **de error** frente a la referencia.

La lectura, sencilla:

- Sumar **territorio, entidad y semana** sí aporta información real: no es complejidad de adorno.
- El GLM le gana tanto a “ponerle a todos el mismo número” como a usar solo la fuente.

El GLM es un buen predictor de la cobertura de seguimiento.

- 1 **Cobertura real: 94,4 %** (ponderada por 3.532.353 casos). El promedio simple (91,95 %) subestima porque da igual peso a grupos grandes y pequeños, y los pequeños tienen más brechas.
- 2 **La fuente es el factor dominante.** CONFIRMADOS 96 % / SOSPECHOSOS 79,9 % / NO AFILIADOS 75,5 %. OR sospechosos $\approx 0,088$ ($p < 0,001$): once veces menos chances que confirmados.
- 3 **Dispersión estructural** ($\eta^2 = 0,886$; árbol exactitud $\approx 0,999$): cuatro regímenes nítidos. No es ruido, es heterogeneidad real.
- 4 **Paradoja de Simpson en NO AFILIADOS.** Cobertura marginal baja (75,5 %), pero OR ajustado > 1 : la inequidad es territorial, no de afiliación.
- 5 **Sobredispersión persistente** ($\phi \approx 2,8-2,9$): exige quasi-binomial para inferencia honesta y motiva un GLMM como próximo paso.
- 6 **El sistema aguantó las olas.** La caída al 35 % en may-2022 refleja el cierre programático del PRASS, no una falla operativa.

CONCLUSIONES Y PRÓXIMOS PASOS

PIPELINE COMPLETO CON HOJA DE RUTA CLARA

Lo logrado:

- Pipeline reproducible: exploración → preprocesamiento → EDA → clustering → GLM → quasi-binomial.
- Brechas accionables con interpretación causal.
- Clustering validado ($\eta^2 = 0,886$).
- Paradoja de Simpson detectada y explicada.
- Módulo `utils.py` con funciones encapsuladas.
- AUC-ROC = 0,878; Brier -22,4 % vs. baseline.

Próximos pasos:

Paso	Descripción
GLMM	Extender: 2.º efecto aleatorio (entidad) y beta-binomial
Ranking	Municipios con mayor brecha ajustada por población
Equidad	¿La brecha en NO AFILIADOS refleja inequidad estructural?
Panel	Dashboard para decisores de política pública

Audiencia: Ministerio de Salud, secretarías departamentales, INS. La priorización es directamente operable.

EL RASTREO FUE LA PRIMERA LÍNEA; LOS DATOS, LA MEMORIA DE LO QUE FALLÓ

“El 5,6 % que no fue seguido no es un residual estadístico.”

“En una pandemia de 3,5 millones de casos,”

son ~ 197.000 personas sin rastreo.”

La ciencia de datos no resuelve pandemias.

Pero puede decirle al sistema **exactamente dónde mirar**
y por qué la brecha persiste.

AUC-ROC	0,878
Pseudo- R^2	0,529
Reducción Brier	22,4 %
η^2 clustering	0,886

Jabes Esteban Monroy Becerra
Especialización en Estadística
UNAL Manizales — Junio 2026

-  Mario Sáenz Espinoza, Jose Goncalves, Paulo Leitao, Jose Luis Gonzalez Sanchez, and Alberto Herreros, *Inverse kinematics of a 10 dof modular hyper-redundant robot resorting to exhaustive and error-optimization methods: A comparative study*, Robotics Symposium and Latin American Robotics Symposium (SBR-LARS), 2012 Brazilian, IEEE, 2012, pp. 125–130.
-  Mario Sáenz Espinoza, Ana I Pereira, and José Gonçalves, *Optimization methods for hyper-redundant robots' inverse kinematics in biomedical applications*, AIP Conference Proceedings, vol. 1479, 2012, p. 818.
- 
-  Ming Tham, *Writing research theses or dissertations*, May 2001, University of Newcastle Upon Tyne.