

Proyecto PRASS: Seguimiento al COVID-19

Especialización en Analítica y Ciencia de Datos - Fundamentos de Ciencia de Datos

Autor: Jabes Monroy

Fuente: Portal de Datos Abiertos de Colombia (datos.gov.co), conjunto r6r5-w84k. Informe resumen de las etapas de exploración, preprocesamiento, análisis exploratorio y modelado.

1. Datos y objetivo

El conjunto registra el seguimiento epidemiológico del programa PRASS (Pruebas, Rastreo y Aislamiento Selectivo Sostenible) en Colombia. Cada fila es un agregado por fuente, fecha, departamento, municipio y entidad reportante, con el número de casos y cuántos recibieron seguimiento. Volumen: **339.646 registros y 12 variables**, sin valores faltantes. El objetivo analítico es cuantificar la **cobertura de seguimiento** e identificar brechas por fuente, territorio y entidad. Todo el trabajo se desarrolla en un cuaderno único que importa el módulo *utils.py* con las funciones reutilizables.

2. Parte I - Exploración y evaluación de calidad

Diagnóstico del dato crudo mediante las siguientes técnicas:

Técnica	En qué consiste y qué se obtuvo
Estructura y tipos (info, dtypes)	Inspección de columnas y tipos. 12 variables; medias muy superiores a las medianas, primer indicio de asimetría.
Estadísticos descriptivos (describe)	Resumen de posición y dispersión. Mediana de casos entre 1 y 2; máximo 31.654 (cola larga).
Datos faltantes (isna)	Conteo de nulos por variable. Resultado: 0 nulos, no se requiere imputación.
Duplicados (duplicated)	Filas completamente repetidas. Resultado: 0 duplicados.
Unicidad y categorías (nunique)	Cardinalidad por variable. Fuente: 3; Departamento: 33; Municipio: 1.121; Entidad: 68.
Inconsistencias de texto (strip, regex)	Espacios al borde y dobles. EntidadRegistro tiene espacios dobles, sin crear categorías nuevas.
Varianza nula (std=0)	Detección de columnas constantes. FechaCorte es constante (sin información) -> a eliminar.
Outliers (IQR / boxplot)	Valores fuera de $[Q1-1.5*IQR, Q3+1.5*IQR]$. ~13% atípicos, pero reflejan el sesgo natural de conteo, no errores.
Coherencia de conteos	Identidad total = con + sin seguimiento. Se cumple en el 100% de los registros.
Calidad de porcentajes	Las columnas de porcentaje están corruptas (100% codificado como 1e22). Decisión: recalcular desde conteos.
Test de Little (MCAR)	Evalúa si los faltantes son completamente aleatorios. No aplica: no hay datos faltantes.

3. Parte II - Preprocesamiento

Transformaciones derivadas de la exploración, encapsuladas en *utils.preprocesar*:

Técnica	En qué consiste y qué se obtuvo
Tipado de fecha (to_datetime)	FechaRegistro de texto a fecha. Rango cubierto: 2020-05-04 a 2022-05-18.
Separación código/nombre (split)	Departamento y Municipio (formato 'código - nombre') divididos en columnas *Codigo y *Nombre.

Técnica	En qué consiste y qué se obtuvo
Estandarización de texto	Recorte y colapso de espacios en EntidadRegistro (0 espacios dobles tras el proceso).
Recálculo de cobertura	$CoberturaConSeguimiento = con/total*100$, en reemplazo de los porcentajes corruptos. Rango coherente [0,100].
Eliminación de columnas	Se descartan FechaCorte (constante), los porcentajes corruptos y los campos territoriales originales.
Diagnóstico y conversión de tipos	Se distinguen identificadores (códigos DIVIPOLA, se conservan como categoría) de numéricas. Categóricas a 'category' y semana ordinal.

Resultado: **df_prep con 13 variables tipadas y sin nulos**, listo para el análisis.

4. Parte III - Análisis exploratorio (EDA)

La cobertura agregada se calcula **ponderada por casos** ($\text{sum(con)}/\text{sum(total)}$), que refleja la cobertura real del sistema y no sobrerrepresenta a los grupos pequeños.

Técnica	En qué consiste y qué se obtuvo
Distribuciones (histogramas log, KDE)	Forma de las variables. Conteos con fuerte asimetría positiva; cobertura concentrada en 100%.
Univariado categórico (pie, barras)	Composición. Predominio de CONFIRMADOS; concentración en Antioquia/Cundinamarca y en NUEVA EPS y Sanitas.
Cobertura global ponderada	Sobre 3.532.353 casos: 94,4% ponderada frente a 92,0% del promedio simple (los grupos grandes cubren mejor).
Bivariado categórico (cobertura por grupo)	Por fuente: CONFIRMADOS 96,0%, SOSPECHOSOS 79,9%, POBLACIÓN NO AFILIADA 75,5%. Heterogeneidad por territorio y entidad.
Bivariado numérico (correlación, scatter)	Correlaciones lineales con la cobertura débiles (máx [0,12]): la relación es no lineal por la saturación en 100%.
Cruce de categorías (heatmap Depto x Fuente)	Las brechas surgen de la interacción territorio-fuente, no de un solo factor.
Análisis temporal (serie mensual)	El volumen dibuja las olas epidémicas; la cobertura se mantuvo alta y estable durante los picos.

5. Parte III.B - ¿La dispersión de la cobertura es estructural?

Antes de afirmar que la cobertura tiene alta dispersión se investiga su causa con un análisis no supervisado. Se agrupan los grupos (K-Means) por su perfil —cobertura, tamaño en escala logarítmica y fuente, estandarizados— y luego se predice el conglomerado con un árbol de decisión, que mide cuán diferenciados están y por cuáles características.

Conglomerado (k=4)	% casos	Cobertura ponderada
Régimen dominante (CONFIRMADOS)	88,6%	97,5%
Brecha dura (CONFIRMADOS)	2,7%	12,4%
SOSPECHOSOS SIVIGILA	7,6%	90,2%
POBLACIÓN NO AFILIADA	1,1%	75,5%

El árbol predice el conglomerado con **exactitud** $\approx 0,999$: los grupos están netamente diferenciados. Las características que los separan son la **fuente** (importancia $\approx 0,56$) y la **cobertura** ($\approx 0,44$); el **tamaño no aporta** (0,000). El eta-cuadrado de la cobertura entre conglomerados es **0,886**. Conclusión: la dispersión es **estructural, no ruido**; su causa es el origen del caso combinado con el régimen de cobertura (coexisten un bloque casi totalmente seguido y un bloque de brecha dura). Esto justifica modelar y no solo describir.

Peso de las variables antes del modelo (reducción de devianza de un GLM binomial de un solo factor): Fuente explica 12,1% de la devianza con solo 2 grados de libertad (el más eficiente); EntidadRegistro 35,7% (67 gl, alta cardinalidad); Departamento 5,0% (32 gl); y la semana 0,3% (irrelevante). Fundamenta los predictores del modelo.

6. Parte IV - Modelado: GLM binomial de la cobertura

En lugar de modelar el porcentaje de cobertura (saturado en 100%), se modela la probabilidad de que un caso reciba seguimiento: de N casos de un grupo, k son seguidos, con $k \sim \text{Binomial}(N, p)$. La familia se elige por el tipo de respuesta (un conteo acotado de éxitos sobre ensayos):

Familia	Soporte	¿Adecuada aquí?
Normal	Real continuo	No: la cobertura está acotada en [0,100] y es heterocedástica.
Gamma	Real positivo	No: para magnitudes positivas continuas.
Poisson	Enteros sin tope	No: k está acotado por N; interesa la proporción k/N.
Binomial	0...N éxitos	Sí: proceso exacto k éxitos en N ensayos; pondera por N; enlace logit en rango.

Modelo base. GLM binomial con enlace logit y predictores Fuente, Departamento, Entidad y semana, ponderado por N. Pseudo-R² por devianza $\approx 0,51$ y estadístico de dispersión $\approx 2,8$ (sobredispersión). Odds ratio de SOSPECHOSOS $\approx 0,09$ frente a CONFIRMADOS (once veces menos probabilidad de seguimiento). POBLACIÓN NO AFILIADA, con menor cobertura marginal, presenta un OR ajustado mayor que 1: un caso de paradoja de Simpson revelado al controlar por territorio y entidad. En prueba, el Brier score ($\approx 0,042$) mejora frente al baseline ($\approx 0,055$) y el AUC-ROC $\approx 0,88$; con desbalance, la especificidad para detectar la brecha es baja ($\approx 0,21$) al umbral 0,5.

Modelo redefinido a partir de los conglomerados. Como el clustering mostró que la brecha vive en la interacción fuente-territorio, se añade el término **Fuente × Departamento** (solo en celdas con soporte y no saturadas, para evitar separación) y se ajusta como **quasi-binomial** (escala fijada en la dispersión de Pearson, errores estándar honestos ante la sobredispersión).

Modelo	Pseudo-R ²	Dispersión	Brier (prueba)
Base (Fuente + Depto + Entidad)	0,514	2,77	0,0425
Redefinido (+ Fuente × Depto, quasi)	0,529	2,94	0,0421

La interacción mejora el ajuste de forma **moderada** (pseudo-R² y Brier algo mejores), pero la **sobredispersión persiste** ($\sim 2,9$): no proviene de un término faltante sino de heterogeneidad intrínseca entre grupos. Por eso la redefinición correcta es doble: el quasi-binomial corrige la inferencia (errores estándar) y, como fondo estructural, se recomienda un modelo jerárquico (beta-binomial / GLMM con efectos aleatorios por territorio y entidad), que el propio análisis de conglomerados ya motivaba.

7. Hallazgos principales

- Cobertura global del **94,4%** (ponderada por casos); el promedio simple (92,0%) la subestima.
- La **fente** es el factor más discriminante: confirmados 96,0% frente a sospechosos 79,9% y no afiliados 75,5%.
- La dispersión de la cobertura es **estructural**: cuatro regímenes nítidos (eta-cuadrado 0,886; árbol con exactitud 0,999), separados por fuente y por la existencia de un bloque de brecha dura.
- El modelo binomial confirma la brecha por fuente (OR sospechosos $\approx 0,09$) y revela una paradoja de Simpson en la población no afiliada al controlar por territorio y entidad.
- La sobredispersión ($\sim 2,8$ - $2,9$) persiste pese a la interacción fuente-territorio: hay heterogeneidad intrínseca entre grupos que exige quasi-binomial y, como fondo, un modelo jerárquico.
- El seguimiento se sostuvo a lo largo de las olas epidémicas del periodo 2020-2022.

8. Conclusiones y próximos pasos

El sistema PRASS alcanzó una cobertura global alta, pero con brechas claras y persistentes en la población no afiliada y en los casos sospechosos, además de diferencias territoriales y por entidad. La calidad del dato es buena (sin faltantes ni duplicados, conteos coherentes), salvo las columnas de porcentaje del origen, corregidas mediante recálculo. El análisis no supervisado demostró que la dispersión de la cobertura responde a una estructura, y el modelado la formalizó: un GLM binomial ponderado, redefinido con la interacción fuente-territorio y ajustado como quasi-binomial, explica e identifica las brechas de forma interpretable y calibrada. El próximo paso es un modelo jerárquico (beta-binomial / GLMM) que capture la heterogeneidad residual entre territorios y entidades, y la priorización accionable de las brechas detectadas.