

Proyecto PRASS: Seguimiento al COVID-19

Especialización en Analítica y Ciencia de Datos - Fundamentos de Ciencia de Datos

Autor: Jabes Monroy

Fuente: Portal de Datos Abiertos de Colombia (datos.gov.co), conjunto r6r5-w84k. Informe resumen de las etapas de exploración, preprocesamiento y análisis exploratorio.

1. Datos y objetivo

El conjunto registra el seguimiento epidemiológico del programa PRASS (Pruebas, Rastreo y Aislamiento Selectivo Sostenible) en Colombia. Cada fila es un agregado por fuente, fecha, departamento, municipio y entidad reportante, con el número de casos y cuántos recibieron seguimiento. Volumen: **339.646 registros y 12 variables**, sin valores faltantes. El objetivo analítico es cuantificar la **cobertura de seguimiento** e identificar brechas por fuente, territorio y entidad. Todo el trabajo se desarrolla en un cuaderno único que importa el módulo *utils.py* con las funciones reutilizables.

2. Parte I - Exploración y evaluación de calidad

Diagnóstico del dato crudo mediante las siguientes técnicas:

Técnica	En que consiste y que se obtuvo
Estructura y tipos (info, dtypes)	Inspección de columnas y tipos. 12 variables; medias muy superiores a las medianas, primer indicio de asimetría.
Estadísticos descriptivos (describe)	Resumen de posición y dispersión. Mediana de casos entre 1 y 2; máximo 31.654 (cola larga).
Datos faltantes (isna)	Conteo de nulos por variable. Resultado: 0 nulos, no se requiere imputación.
Duplicados (duplicated)	Filas completamente repetidas. Resultado: 0 duplicados.
Unicidad y categorías (nunique, value_counts)	Cardinalidad por variable. Fuente: 3; Departamento: 33; Municipio: 1.121; Entidad: 68.
Inconsistencias de texto (strip, regex)	Espacios al borde y dobles. EntidadRegistro tiene espacios dobles, sin crear categorías nuevas.
Varianza nula (std=0)	Detección de columnas constantes. FechaCorte es constante (sin información) -> a eliminar.
Outliers (IQR / boxplot)	Valores fuera de $[Q1-1.5*IQR, Q3+1.5*IQR]$. ~13% atípicos, pero reflejan el sesgo natural de conteo, no errores.
Coherencia de conteos	Identidad total = con + sin seguimiento. Se cumple en el 100% de los registros.
Calidad de porcentajes	Las columnas de porcentaje están corruptas (100% codificado como 1e22). Decisión: recalcular desde conteos.
Test de Little (MCAR)	Evalúa si los faltantes son completamente aleatorios. No aplica: no hay datos faltantes.

3. Parte II - Preprocesamiento

Transformaciones derivadas de la exploración, encapsuladas en *utils.preprocesar*:

Técnica	En que consiste y que se obtuvo
Tipado de fecha (to_datetime)	FechaRegistro de texto a fecha. Rango cubierto: 2020-05-04 a 2022-05-18.
Separación código/nombre (split)	Departamento y Municipio (formato 'código - nombre') divididos en columnas *Código y *Nombre.
Estandarización de texto	Recorte y colapso de espacios en EntidadRegistro (0 espacios dobles tras el proceso).
Recálculo de cobertura	CoberturaConSeguimiento = $\text{con}/\text{total} \times 100$, en reemplazo de los porcentajes corruptos. Rango coherente $[0,100]$.
Eliminación de columnas	Se descartan FechaCorte (constante), los porcentajes corruptos y los campos territoriales originales.
Diagnóstico y conversión de tipos	Se distinguen identificadores (códigos DIVIPOLA, se conservan como categoría) de numéricas. Categóricas a 'category' y semana ordinal.

Resultado: **df_prep** con **13 variables tipadas y sin nulos**, listo para el análisis.

4. Parte III - Analisis exploratorio (EDA)

La cobertura agregada se calcula **ponderada por casos** ($\text{sum}(\text{con})/\text{sum}(\text{total})$), que refleja la cobertura real del sistema y no sobrerrepresenta a los grupos pequenos.

Tecnica	En que consiste y que se obtuvo
Distribuciones (histogramas log, KDE)	Forma de las variables. Conteos con fuerte asimetria positiva; cobertura concentrada en 100%.
Univariado categorico (pie, barras)	Composicion. Predominio de CONFIRMADOS; concentracion en Antioquia/Cundinamarca y en NUEVA EPS y Sanitas.
Cobertura global ponderada	Sobre 3.532.353 casos: 94,4% ponderada frente a 92,0% del promedio simple (los grupos grandes cubren mejor).
Bivariado categorico (cobertura por grupo)	Por fuente: CONFIRMADOS 96,0%, SOSPECHOSOS 79,9%, POBLACION NO AFILIADA 75,5%. Heterogeneidad por territorio y entidad.
Bivariado numerico (correlacion, heatmap, scatter)	Correlaciones lineales con la cobertura debiles (max 0,12): la relacion es no lineal por la saturacion en 100%.
Cruce de categorias (heatmap Depto x Fuente)	Las brechas surgen de la interaccion territorio-fuente, no de un solo factor.
Analisis temporal (serie mensual)	El volumen dibuja las olas epidemicas; la cobertura se mantuvo alta y estable durante los picos.

5. Hallazgos principales

- Cobertura global del **94,4%** (ponderada por casos); el promedio simple (92,0%) la subestima.
- La **fuente** es el factor mas discriminante: confirmados 96,0% frente a sospechosos 79,9% y no afiliados 75,5%.
- Existe heterogeneidad territorial y entre entidades; las brechas dependen de la interaccion territorio-fuente.
- Distribucion fuertemente asimetrica y cobertura saturada en 100%; los atipicos reflejan el fenomeno, no errores.
- El seguimiento se sostuvo a lo largo de las olas epidemicas del periodo 2020-2022.

6. Conclusiones y proximos pasos

El sistema PRASS alcanzo una cobertura global alta, pero con brechas claras y persistentes en la poblacion no afiliada y en los casos sospechosos, ademas de diferencias territoriales y por entidad. La calidad del dato es buena (sin faltantes ni duplicados, conteos coherentes), salvo las columnas de porcentaje del origen, que fueron corregidas mediante recalcuulo. La siguiente etapa propuesta es el **modelado**, orientado a explicar o predecir la cobertura a partir de la fuente, el territorio, la entidad y el tamano del grupo, considerando la relacion no lineal identificada.